PANDUAN TUGAS TAKE-HOME MAHASISWA

Studi Komparatif Empiris Model Generatif: Autoencoder (Vanilla & Sparse), GAN (Vanilla & DCGAN), VAE, dan DDPM disertai Pembuktian Batasan Teoretis Model Klasifikasi untuk Image Generation

Dosen Pengampu	Muhammad Fikri Hasani, S.Kom., M.T. & Tim Dosen Pengampu D6421
Topik Perkuliahan	Sesi 07: Generative Models (GANs & Diffusion) terintegrasi Sesi 06 (Autoencoders)
Sifat & Bentuk Pengerjaan	Tugas Mandiri / Individu (Proyek Eksperimen Komparatif)
Luaran Akhir	Laporan Ilmiah Komprehensif (PDF, 10-12 Halaman) + Repositori Publik GitHub

1. Latar Belakang Masalah dan Tujuan Pembelajaran

Pemodelan data tanpa supervisi (unsupervised representation learning) merupakan fondasi dalam rekayasa deep learning modern. Sesi perkuliahan 06 membahas kompresi representasi melalui Autoencoder deterministik (Vanilla Autoencoder dan Sparse Autoencoder) serta pemodelan probabilistik Variational Autoencoder (VAE). Sesi perkuliahan 07 memperluas paradigma menuju pemodelan generatif modern: Generative Adversarial Networks (Vanilla GAN berbasis fully connected dan Deep Convolutional GAN / DCGAN) serta Denoising Diffusion Probabilistic Models (DDPM). Masing-masing keluarga arsitektur memiliki karakteristik perumusan matematis, fungsi loss objektif, serta kompromi rekayasa (trade-off) yang berbeda pada kualitas sampel, inference latency, dan kestabilan optimasi.

Tugas proyek mandiri ini mengintegrasikan materi Sesi 06 dan Sesi 07 ke dalam studi komparatif empiris berskala penuh. Mahasiswa ditugaskan untuk mengimplementasikan, melatih, mengevaluasi, serta membandingkan enam arsitektur generatif pada benchmark dataset yang sama secara terstandarisasi. Selain mengevaluasi model generatif, mahasiswa wajib merancang eksperimen pembuktian matematis dan empiris untuk menunjukkan batasan model klasifikasi terawasi (discriminative classifier) dalam menghasilkan sampel citra baru.

- **Vanilla Autoencoder**
- **Sparse Autoencoder**
- **Generative Adversarial Network (GAN)**
- **Variational Autoencoder (VAE)**
- **Deep Convolutional GAN (DCGAN)**
- **Denoising Diffusion Probabilistic Models (DDPM)**

> 📌 **PRINSIP EVALUASI TERSTANDARISASI**
> Seluruh model generatif wajib dilatih menggunakan dataset yang sama, train-val-test split yang seragam, serta penetapan random seed yang tetap (misalnya: `torch.manual_seed(42)` dan `np.random.seed(42)`). Standardisasi ini diperlukan agar perbedaan performa empiris murni mencerminkan inductive bias masing-masing keluarga model.

2. Pembuktian Batasan Teoretis Model Klasifikasi untuk Image Generation

Pada perancangan arsitektur deep learning, struktur lapisan ekstraksi fitur pada Multi-Layer Perceptron (MLP) Classifier (misalnya pemetaan dimensi $784 \rightarrow 256 \rightarrow 64$) tampak identik secara struktural dengan bagian Encoder pada Autoencoder. Meskipun demikian, setelah melewati beberapa lapisan tersembunyi (hidden layers), matriks bobot $W^{(l)}$ dan representasi fitur

laten (z_{MLP}) yang diperoleh untuk klasifikasi tidak dapat langsung digunakan untuk merekonstruksi maupun menyintesis citra baru (image generation).

Hal ini disebabkan oleh tiga batasan matematis utama: (1) MLP Classifier meminimalkan Cross-Entropy Loss untuk memodelkan probabilitas kondisional $P(y \mid x)$, sehingga jaringan membuang variasi spasial intra-kelas dan hanya menyisakan fitur pembeda kelas (information bottleneck); (2) matriks bobot persegi panjang $W^{(l)}$ tidak bersifat ortogonal maupun invertibel ($\left(W^{(l)}\right)^T W^{(l)} \neq \mathbf{I}$) serta fungsi aktivasi $\text{ReLU}(u) = max(0, u)$ memotong nilai negatif secara ireversibel; dan (3) ruang fitur laten z_{MLP} tidak memiliki regularisasi kerapatan prior $P(z)$. Mahasiswa wajib membuktikan ketiga batasan ini secara empiris melalui eksperimen kode.

2.1 Prosedur Eksperimen Mandiri: Pembuktian Ketidakmampuan Bobot dan Latent Features MLP Classifier untuk Image Generation

Tahapan eksperimen pembuktian empiris yang wajib dijalankan oleh setiap mahasiswa:

- **Tahap 1: Pelatihan MLP Classifier Berjenjang:** Latih satu arsitektur Multi-Layer Perceptron (MLP) Classifier pada benchmark dataset pilihan dengan dimensi lapisan tersembunyi yang menyerupai Encoder Autoencoder (misalnya: $784 \rightarrow 256 \rightarrow 64 \rightarrow 10$) menggunakan Cross-Entropy Loss hingga mencapai akurasi test set minimal 88%. Simpan matriks bobot terlatih (W_1, W_2, W_3) dan ekstrak representasi fitur laten $z_{\text{MLP}} \in \mathbb{R}^{64}$ pada lapisan sebelum klasifikasi akhir.
- **Tahap 2: Proyeksi Balik Bobot Langsung dari Vektor Kelas (Top-Down Weight Transposition):** Gunakan matriks bobot MLP Classifier yang telah terlatih untuk memproyeksikan balik vektor one-hot kelas target $y_c \in \mathbb{R}^{10}$ menuju ruang piksel tanpa pelatihan tambahan melalui operasi transpos matriks: $\hat{z} = \text{ReLU}(W_3^T y_c)$, dilanjutkan $\hat{h}_1 = \text{ReLU}(W_2^T \hat{z})$, hingga $\hat{x} = \text{Sigmoid}(W_1^T \hat{h}_1)$. Tunjukkan secara visual bahwa citra $\hat{x}$ yang dihasilkan berupa pola bercak kabur (superposisi template bobot kasar) karena $W^T \neq W^{-1}$.
- **Tahap 3: Proyeksi Balik dari Latent Features Citra Uji (Latent Transpose Projection):** Ambil vektor fitur laten $z_{\text{MLP}} \in \mathbb{R}^{64}$ hasil ekstraksi citra uji riil, kemudian proyeksikan langsung ke ruang piksel menggunakan transpos bobot lapisan ekstraktor fitur: $\hat{x} = \text{Sigmoid}(W_1^T \text{ReLU}(W_2^T z_{\text{MLP}}))$. Bandingkan hasilnya terhadap citra asli guna membuktikan bahwa bobot maju (forward weights) klasifikasi tidak dapat langsung dibalik menjadi dekoder rekonstruktif.
- **Tahap 4: Evaluasi Kandungan Informasi Latent Features (Frozen Latent Decoding):** Bekukan seluruh bobot MLP Classifier (requires_grad = False). Latih satu jaringan Decoder MLP terpisah ($64 \rightarrow 256 \rightarrow 784$) menggunakan MSE Loss untuk merekonstruksi citra asli dari fitur laten z_{MLP} yang dibekukan. Bandingkan metrik rekonstruksinya (MSE, PSNR, SSIM) terhadap Vanilla Autoencoder berdimensi laten sama ($z_{\text{AE}} \in \mathbb{R}^{64}$) untuk membuktikan hilangnya detail spasial intra-kelas akibat ekstraksi fitur diskriminatif.
- **Tahap 5: Uji Sampling Generatif pada Ruang Laten MLP Classifier:** Hitung vektor rata-rata μ_z dan simpangan baku σ_z dari fitur laten z_{MLP} pada test set, lalu tarik sampel acak $z_{\text{rand}} \sim \mathcal{N}(\mu_z, \text{diag}(\sigma_z^2))$ dan teruskan ke Decoder dari Tahap 4. Dokumentasikan bahwa citra hasil sampling gagal membentuk struktur objek baru yang utuh karena ruang laten MLP Classifier tidak membentuk generative manifold yang kontinu dan teratur.

3. Pilihan Benchmark Dataset dan Standar Preprocessing

Mahasiswa wajib memilih satu dari benchmark dataset publik berikut. Dataset diunduh secara legal melalui pustaka torchvision.datasets tanpa memerlukan registrasi berbayar:

Benchmark Dataset	Dimensi & Format	Tingkat Kompleksitas	Akses via PyTorch
Fashion-MNIST (Sangat Direkomendasikan)	28x28 Grayscale, 10 Kategori Pakaian (Fashion Items), 70.000 citra	Menengah (kontur tekstil, variasi siluet)	torchvision.datasets.FashionMNIST
MNIST (Standar Benchmark)	28x28 Grayscale, 10 Digit Angka (0-9), 70.000 citra	Dasar (latar hitam, goresan stroke biner)	torchvision.datasets.MNIST

Kuzushiji-MNIST (KMNIST)	28x28 Grayscale, 10 Karakter Hiragana Kuno, 70.000 citra	Menengah (kaligrafi cursive tradisional)	torchvision.datasets.KMNIST
CIFAR-10	32x32 RGB (3 Kanal), 10 Kategori Objek Riil, 60.000 citra	**Tinggi** (foto natural, variasi latar kompleks)	torchvision.datasets.CIFAR10

Aturan Standardisasi Preprocessing:

- Dataset Split: Bagi dataset menjadi Train Set (80%), Validation Set (10%), dan Test Set (10%). Seluruh metrik numerik wajib dievaluasi pada Test Set yang belum pernah dilihat model.
- Batch Size & DataLoader: Gunakan batch_size = 128 atau 256 dengan shuffle=True pada training set dan shuffle=False pada validation/test set.

4. Pertanyaan Penyelidikan Ilmiah (Pertanyaan Inti Eksperimen)

Mahasiswa wajib menyajikan analisis komparatif mendalam pada laporan akhir dengan menjawab enam pertanyaan penelitian berikut:

- **Q1: Perbandingan Kuantitatif: Reconstruction Fidelity vs Generative Quality:** Bagaimana komparasi kuantitatif kemampuan rekonstruksi antara Vanilla Autoencoder, Sparse Autoencoder, dan Variational Autoencoder (VAE) yang dievaluasi melalui metrik Test MSE, Test PSNR, dan Test SSIM? Jelaskan bagaimana penambahan penalti regularisasi sparsity $\lambda\|h\|_1$ pada representasi laten Sparse AE memengaruhi fidelitas rekonstruksi jika dibandingkan dengan representasi padat Vanilla AE. Selanjutnya, bagaimana perbandingan metrik FID (Fréchet Inception Distance) antarmodel generatif: VAE, Vanilla GAN (berbasis MLP), DCGAN, dan DDPM saat menyintesis sampel citra baru dari prior derau acak $z \sim \mathcal{N}(0, I)$?
- **Q2: Analisis Blurriness vs Sharp Edges dan Representasi Fitur:** Mengapa perumusan pixel-wise reconstruction loss (MSE / BCE) pada Vanilla AE, Sparse AE, dan VAE menghasilkan visual rekonstruksi yang cenderung buram (blurry), sedangkan adversarial loss pada Vanilla GAN dan DCGAN menghasilkan kontur dan tekstur citra yang tajam? Jelaskan fenomena ini berdasarkan perbedaan estimasi ekspektasi kondisional $\mathbb{E}[x|z]$ versus minimisasi divergensi Jensen-Shannon $D_{\mathrm{JS}}(P_{\mathrm{data}} \parallel P_g)$. Uraikan pula perbedaan struktur fitur yang dipelajari pada hidden layer Sparse AE akibat penalti jarang terhadap representasi fitur Vanilla AE.
- **Q3: Stabilitas Training, Dinamika Arsitektur, dan Generative Trilemma:** Bagaimana perbandingan dinamika stabilitas kurva loss selama pelatihan antara Vanilla GAN (arsitektur MLP/Fully-Connected) dengan DCGAN (arsitektur konvolusional penuh)? Analisis penyebab munculnya fenomena vanishing gradient atau mode collapse pada Vanilla GAN serta prinsip arsitektur DCGAN yang memitigasi kendala tersebut. Bandingkan pula stabilitas optimasi minimax game pada GAN dengan supervised noise prediction objektif pada DDPM. Evaluasi trade-off Generative Trilemma (Sample Quality, Sampling Speed, Mode Coverage) dengan membandingkan latensi inferensi per batch (64 sampel citra) antara generator satu langkah (single-pass pada Vanilla GAN, DCGAN, dan VAE) terhadap multi-step iterative denoising pada DDPM.
- **Q4: Struktur Latent Space dan Eksperimen Interpolasi:** Bagaimana karakteristik transisi visual saat dilakukan linear latent interpolation $z(\alpha) = (1-\alpha)z_A + \alpha z_B$ dengan $\alpha \in [0.0, 0.2, 0.4, 0.6, 0.8, 1.0]$ pada VAE, DCGAN, Vanilla GAN, Sparse AE, dan Vanilla AE? Jelaskan penyebab terbentuknya artefak visual rusak pada model berbasis Autoencoder deterministik (Vanilla AE dan Sparse AE) ketika vektor laten melintasi wilayah kosong (latent space voids) jika dibandingkan dengan manifold laten kontinu yang teratur pada VAE.
- **Q5: Pembuktian Ketidakmampuan Bobot dan Fitur Laten MLP Classifier untuk Image Generation:** Berdasarkan hasil eksperimen pada Bagian 2, jelaskan alasan matematis dan empiris mengapa matriks bobot $W^{(l)}$ serta representasi fitur laten z_{MLP} dari MLP Classifier tidak dapat langsung digunakan untuk merekonstruksi maupun men-generate citra baru (baik melalui proyeksi balik transpos bobot W^T, dekoder terpisah pada fitur laten beku, maupun prior sampling). Tinjau fenomena ini dari perspektif pemodelan conditional probability $P(y \mid x)$ (information bottleneck yang membuang variasi intra-kelas), sifat matriks bobot non-ortogonal ($W^T W \neq \mathbf{I}$), serta ketiadaan regularisasi kerapatan ruang laten $P(z)$.
- **Q6: Sintesis Rekayasa dan Rekomendasi Industri:** Berdasarkan evaluasi empiris keenam model yang diuji (Vanilla AE, Sparse AE, Vanilla GAN, VAE, DCGAN, DDPM), tentukan arsitektur yang paling tepat untuk: (1) Deteksi anomali tanpa

supervisi pada citra inspeksi manufaktur (evaluasi antara Vanilla AE dan Sparse AE berdasarkan sensitivitas reconstruction error), (2) Filter avatar interaktif waktu-nyata pada perangkat mobile dengan anggaran latensi inferensi <30 ms (evaluasi antara Vanilla GAN, DCGAN, dan VAE), dan (3) Pembuatan aset visual beresolusi dan berfidelitas tinggi untuk industri kreatif (evaluasi DCGAN versus DDPM). Sertakan argumen teknis berdasarkan metrik empiris dan inductive bias masing-masing model.

5. Struktur dan Sistematika Laporan Akhir Mahasiswa

Laporan akhir disusun dalam format PDF dengan panjang 10 hingga 12 halaman. Mahasiswa diwajibkan menyusun naskah secara tertib mengikuti struktur publikasi ilmiah berikut:

- **Bagian I: Identitas Penulis dan Tautan Repositori GitHub.** Memuat Nama Lengkap, NIM, Kelas, serta TAUTAN AKTIF repositori GitHub yang dapat diakses publik. Repositori wajib memuat skrip modular PyTorch, berkas requirements.txt, README petunjuk eksekusi, serta git commit history bertahap yang mencerminkan kemandirian pengerjaan.
- **Bagian II: Landasan Teori, Desain Arsitektur, dan Formulasi Matematika.** Diagram skematik arsitektur keenam model generatif (Vanilla AE, Sparse AE, Vanilla GAN, VAE, DCGAN, DDPM) serta satu model MLP Classifier pendamping. Tabel konfigurasi parameter (lapisan arsitektur, dimensi laten, fungsi aktivasi, optimizer, learning rate) serta formulasi matematika loss function lengkap untuk masing-masing model.
- **Bagian III: Pembuktian Teoretis dan Empiris Batasan MLP Classifier untuk Image Generation.** Uraian matematis perbedaan pemodelan $P(y \mid x)$ berbanding $P(x)$ serta sifat ketidakbalikan matriks bobot $W^T \neq W^{-1}$. Penyajian hasil eksperimen proyeksi balik transpos bobot, evaluasi frozen latent decoder (z_{MLP} berbanding z_{AE}), serta hasil uji prior sampling pada ruang laten MLP Classifier.
- **Bagian IV: Tabel Komparasi Metrik Numerik (Kompilasi Kuantitatif).** Tabel perbandingan menyeluruh hasil evaluasi pada Test Set untuk keenam model yang mencakup dimensi laten, training time per epoch, inference latency per batch (64 sampel), Test MSE, Test PSNR, Test SSIM, FID Score untuk sampel sintetis, serta catatan kestabilan training.
- **Bagian V: Kompilasi Lima Visualisasi Komparatif Utama.** Penyajian lima figur visual dengan resolusi tinggi, penomoran resmi, serta analisis visual komparatif antarmodel.
- **Bagian VI: Pembahasan Kritis, Jawaban Pertanyaan Penelitian, dan Rekomendasi Industri.** Diskusi mendalam mengenai temuan empiris, analisis jawaban terperinci atas pertanyaan Q1 sampai Q6, verifikasi teori Generative Trilemma, serta rekomendasi pemilihan model untuk deployment industri nyata.

Template Tabel Metrik Komparatif (Bagian IV Laporan):

Arsitektur Model	Dim Laten	Training Time / Epoch (s)	Latency (ms / batch 64)	Test MSE	Test PSNR (dB)	FID Score	Kestabilan Training
Vanilla Autoencoder	32 atau 64	[diisi mhs]	[diisi mhs]	[diisi mhs]	[diisi mhs]	N/A (Latent Voids)	Stabil / Konvergen
Sparse Autoencoder	32 atau 64 (Bottleneck) / 256 (Sparse)	[diisi mhs]	[diisi mhs]	[diisi mhs]	[diisi mhs]	N/A (Latent Voids)	Stabil / Konvergen
Variational Autoencoder (VAE)	32 atau 64	[diisi mhs]	[diisi mhs]	[diisi mhs]	[diisi mhs]	[diisi mhs]	Stabil / Konvergen
Generative Adversarial Network (GAN)	64 atau 100 (Prior Noise)	[diisi mhs]	[diisi mhs]	N/A (Tanpa Encoder)	N/A	[diisi mhs]	Sangat Rentan Osilasi / Mode Collapse
Deep Convolutional GAN (DCGAN)	100 (Prior Noise)	[diisi mhs]	[diisi mhs]	N/A (Tanpa Encoder)	N/A	[diisi mhs]	Cukup Stabil (Sensitif Arsitektur)
Denoising Diffusion	28x28 (Dimensi Citra)	[diisi mhs]	[diisi mhs]	N/A (Denoising Model)	N/A	[diisi mhs]	Sangat Stabil

Probabilistic Models (DDPM)

Rincian Lima Visualisasi Wajib pada Bagian V Laporan:

- **Figur 1: Grid Rekonstruksi Side-by-Side:** Tampilkan minimal 8 sampel citra dari Test Set. Baris 1: Citra Asli (Ground Truth); Baris 2: Rekonstruksi Vanilla AE; Baris 3: Rekonstruksi Sparse AE; Baris 4: Rekonstruksi VAE. Sajikan analisis perbandingan ketajaman detail kontur, pelestarian fitur lokal akibat regularisasi penalti sparsity, dan efek keburaman (blurriness).
- **Figur 2: Grid Random Generative Sampling:** Sajikan minimal 16 sampel citra hasil sintesis acak berukuran kisi 4x4 untuk masing-masing model generatif: Panel A: Sampel VAE dari prior $z \sim \mathcal{N}(0, I)$; Panel B: Sampel Vanilla GAN dari $z \sim \mathcal{N}(0, I)$; Panel C: Sampel DCGAN dari $z \sim \mathcal{N}(0, I)$; Panel D: Sampel DDPM dari proses reverse denoising $x_T \sim \mathcal{N}(0, I)$. Evaluasi kualitas tekstur, ketajaman kontur struktural, serta keberagaman ragam mode (mode diversity) antarmodel.
- **Figur 3: Bukti Empiris Batasan Bobot dan Latent Features MLP Classifier:** Sajikan perbandingan visual empat panel: (1) Citra Asli (Ground Truth), (2) Hasil proyeksi balik langsung transpos bobot W^T dari vektor kelas y_c dan fitur laten z_{MLP}, (3) Hasil rekonstruksi Frozen Latent Decoder dari z_{MLP} dibandingkan terhadap rekonstruksi Vanilla AE (z_{AE}), serta (4) Hasil random prior sampling $z_{\text{rand}} \sim \mathcal{N}(\mu_z, \text{diag}(\sigma_z^2))$ pada ruang laten MLP Classifier.
- **Figur 4: Linear Latent Space Interpolation:** Pilih dua titik sampel laten z_A dan z_B dari dua kelas yang kontras. Lakukan interpolasi linier $z(\alpha) = (1 - \alpha)z_A + \alpha z_B$ dengan $\alpha \in [0.0, 0.2, 0.4, 0.6, 0.8, 1.0]$. Dekodekan titik-titik tersebut pada Vanilla AE, Sparse AE, VAE, Vanilla GAN, dan DCGAN, lalu bandingkan kontinuitas transisi visual antarmodel serta kemunculan artefak visual.
- **Figur 5: Training Loss Curves dan DDPM Denoising Trajectory:** Plot kurva training loss terhadap epoch untuk keenam model yang dievaluasi (menampilkan kurva loss rekonstruksi, kurva loss Generator dan Discriminator pada Vanilla GAN dan DCGAN, serta loss prediksi derau pada DDPM). Pada panel model difusi, visualisasikan sekuens reverse diffusion langkah demi langkah ($x_T \rightarrow x_0$) untuk memperlihatkan proses rekonstruksi citra secara bertahap dari derau acak.

6. Rubrik Penilaian dan Distribusi Bobot Evaluasi (Total 100%)

Komponen Evaluasi	Bobot	Kriteria Kualitas Utama
Repositori GitHub & Reproduktibilitas Kode	**15%**	Kode PyTorch terstruktur, modular, terdokumentasi rapi, requirements.txt lengkap, penetapan random seed tetap, serta git commit history mencerminkan proses pengerjaan bertahap.
Implementasi Arsitektur & Training Pipeline	**25%**	Keenam arsitektur (Vanilla AE, Sparse AE, GAN, VAE, DCGAN, DDPM) diimplementasikan sesuai formulasi matematika yang benar, loss function tepat, dan proses optimasi mencapai konvergensi tanpa galat numerik.
Eksperimen Pembuktian Batasan MLP Classifier	**15%**	Eksperimen pembuktian batasan bobot (W^T) dan fitur laten (z_{MLP}) pada MLP Classifier dijalankan secara valid, komparasi terhadap Autoencoder tersaji lengkap, serta analisis teoretis pemodelan $P(y \mid x)$ diuraikan secara mendalam.
Pengujian Kuantitatif & Tabel Metrik	**15%**	Tabel komparasi metrik terisi lengkap pada Test Set (MSE, PSNR, SSIM, FID, latency), pengukuran dilakukan secara objektif, serta parameter pengujian sepadan antarmodel.
Kualitas Visualisasi Komparatif (5 Figur Wajib)	**15%**	Kelima figur visual disajikan dengan ketajaman tinggi, label terbaca jelas, tata letak rapi, serta menyertakan analisis komparatif visual yang tajam.

Kedalaman Analisis Ilmiah & Laporan	**15%**	Pembahasan menyeluruh atas seluruh pertanyaan penelitian Q1 sampai Q6, sintesis fenomena Generative Trilemma, serta rekomendasi deployment industri yang rasional dan bebas plagiarisme.

7. Ketentuan Pengumpulan dan Integritas Akademik

- **Format Berkas Pengumpulan:** Berkas laporan tunggal berformat PDF dengan konvensi penamaan resmi: TUGAS_DL_SESI07_[NIM]_[NAMA_LENGKAP].pdf.
- **Tautan Repositori GitHub:** Dicantumkan pada halaman judul laporan. Repositori wajib berstatus publik agar tim dosen dan asisten laboratorium dapat meninjau kode sumber serta riwayat pengerjaan.
- **Batas Waktu Pengumpulan:** Sesuai dengan yang ditetapkan pada forum di Binusmaya (LMS).
- **Integritas Akademik & Kebijakan Plagiarisme:** Penggunaan AI coding assistant atau LLM **diperkenankan sebatas referensi sintaksis pemrograman dan penelusuran dokumentasi pustaka. Mahasiswa wajib memahami secara mandiri setiap baris kode dan narasi pembahasan yang diajukan**.

> 📌 **PESAN TIM DOSEN PENGAMPU**
>
> Fokuskan pembahasan laporan pada analisis mendalam mengenai hubungan kausalitas matematis antara loss function dengan karakteristik visual masing-masing model. Tunjukkan penguasaan konsep mengenai alasan mengapa model berperilaku demikian, di samping melaporkan angka metrik empiris yang diperoleh.